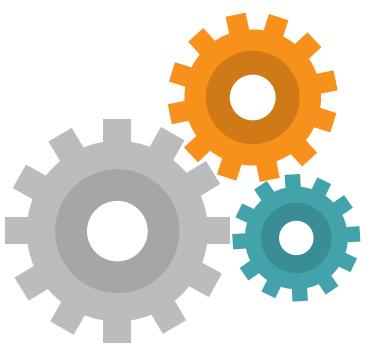


scikit learn

Présenté par :
Abderrahman Salhi
Maryame laouina



Supervisé par :
Qaffou Issam



Plan

Introduction

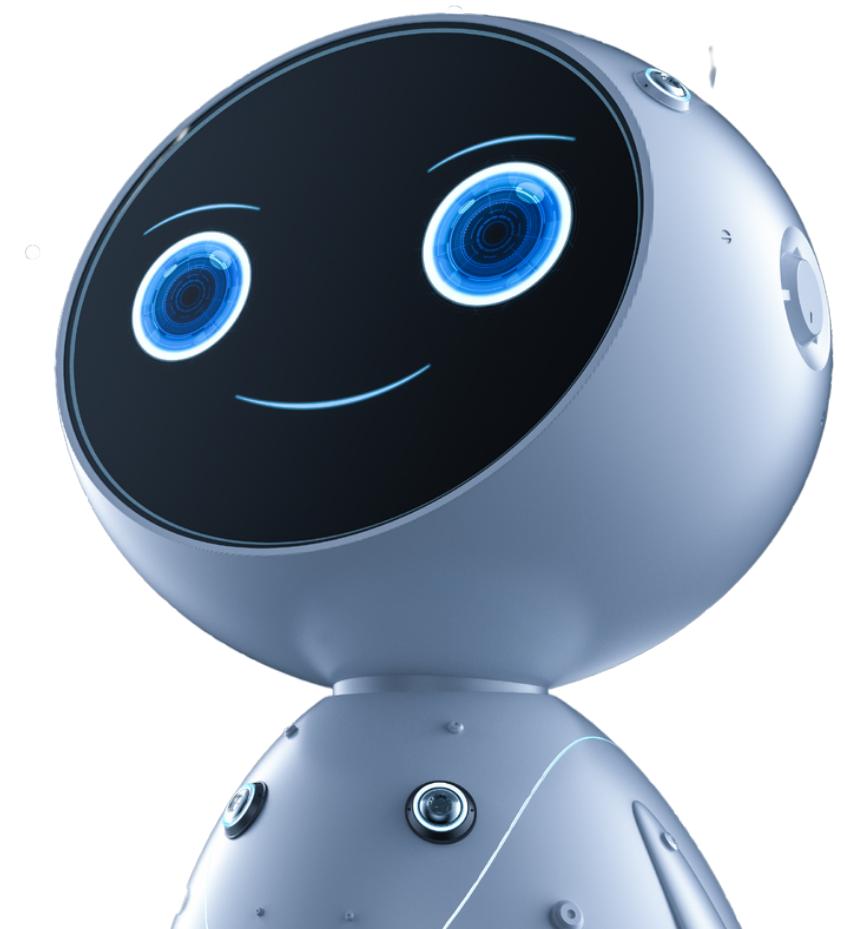
Définition et installation de scikit learn

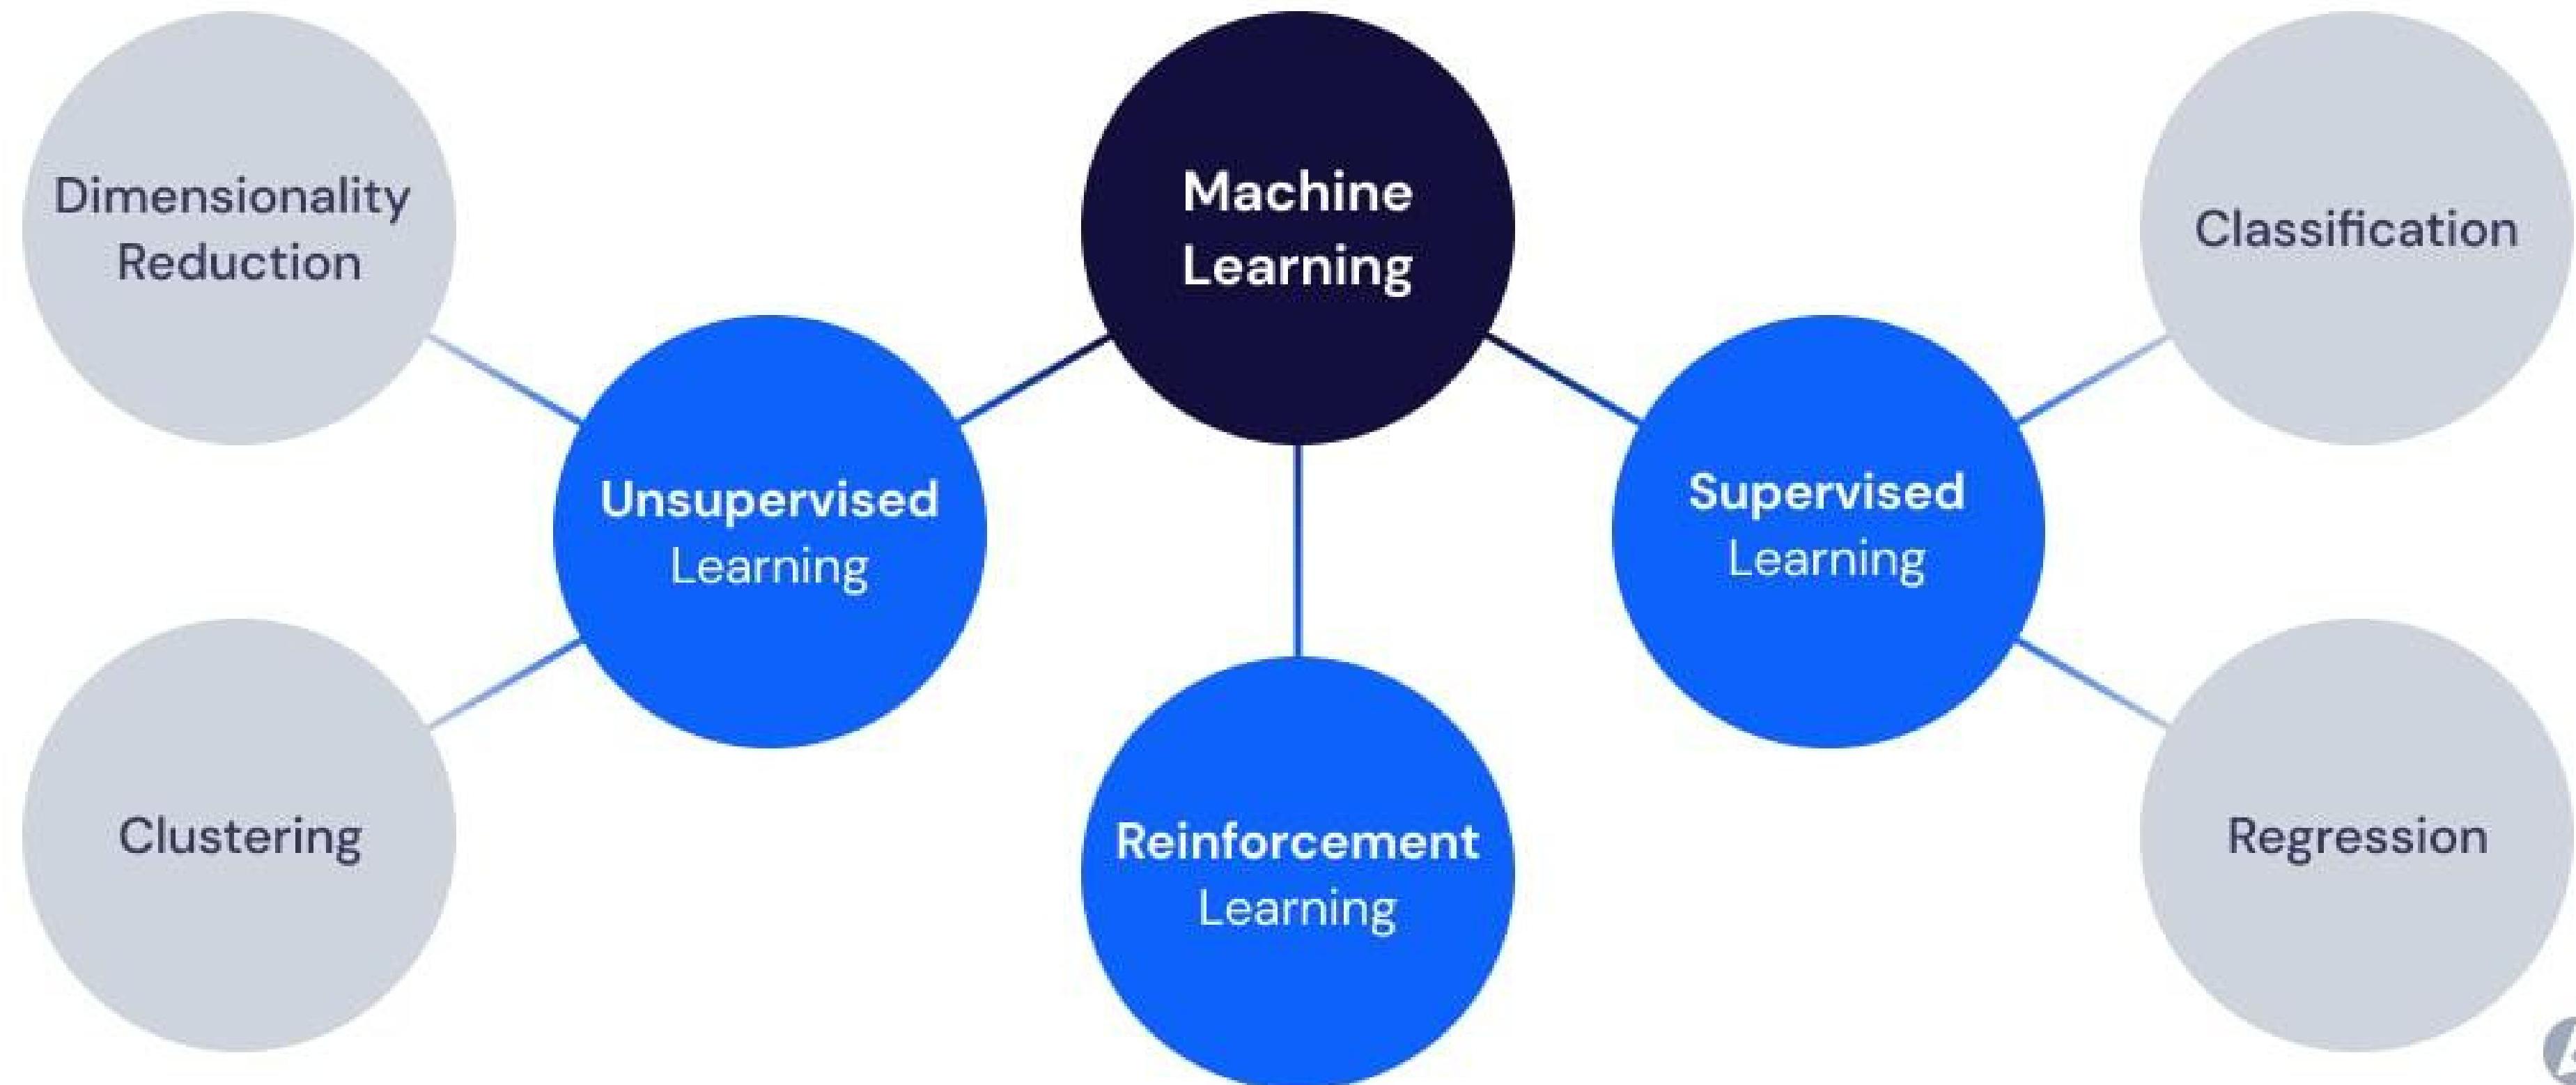
les modules de scikit learn et ses domaines d'utilisation

Comment choisir le meilleur algorithme ?

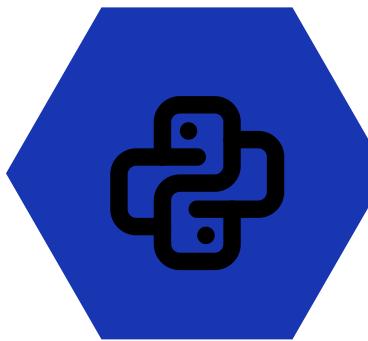
Démonstration

Conclusion

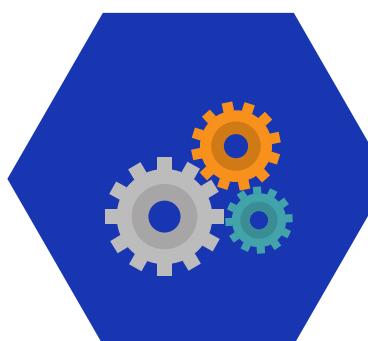




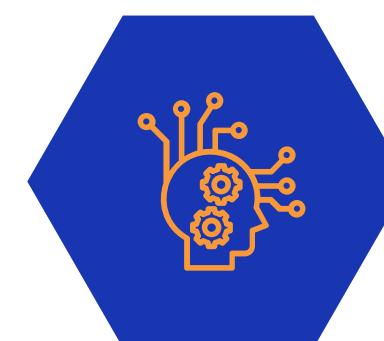
c'est quoi scikit learn ?



Une bibliothèque
Python open source



Utilisée dans l'apprentissage
automatique



Basée sur plusieurs
bibliothèques : scipy,
numpy, matplotlib

Qui utilise scikit learn ?

Booking.com



Spotify



Instalation

Packager pip

Install the 64bit version of Python 3, for instance from <https://www.python.org>.

Then run:

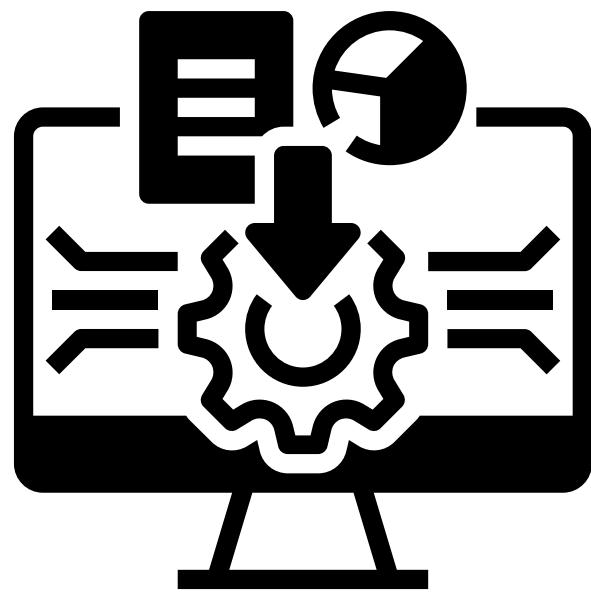
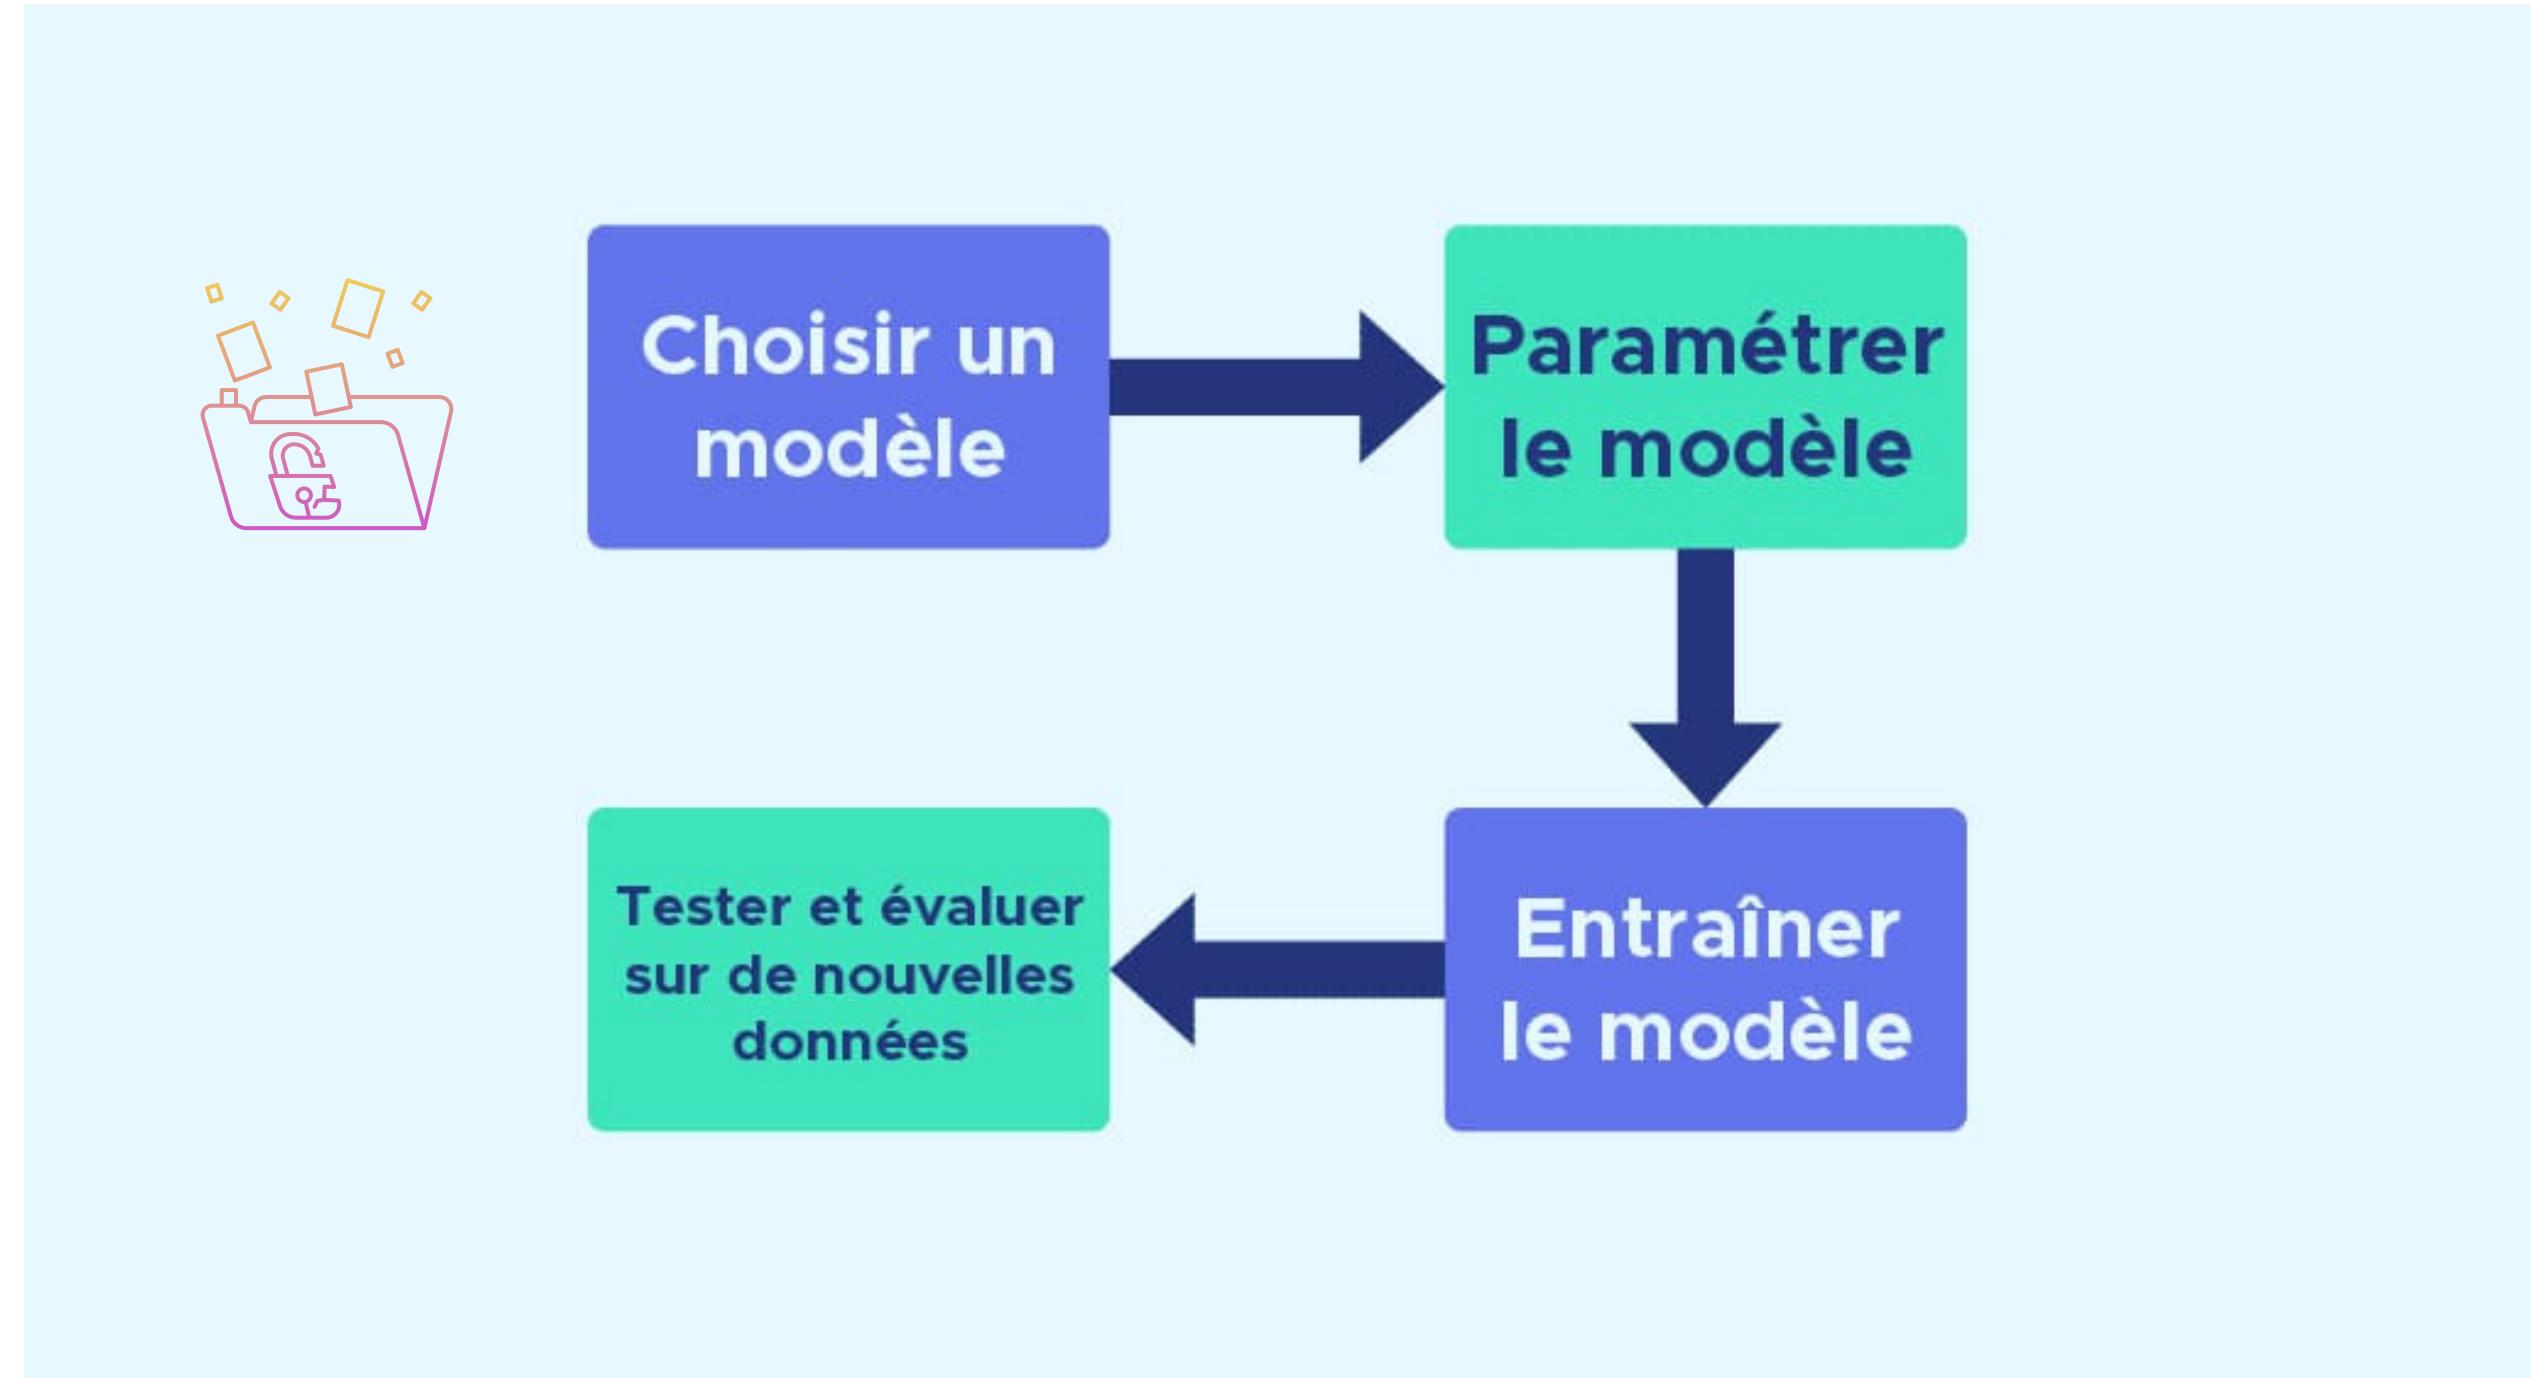
```
$ pip install -U scikit-learn
```

Packager conda

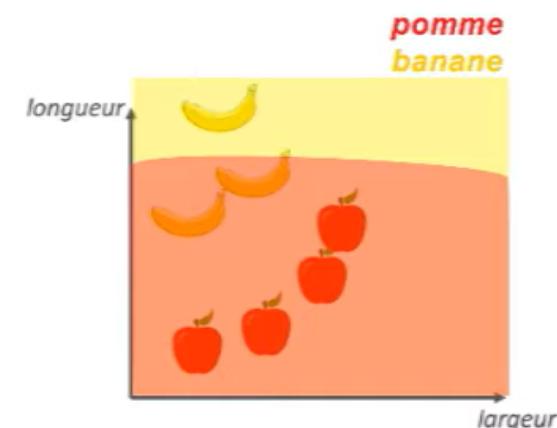
```
$ conda create -n sklearn-env -c conda-forge scikit-learn  
$ conda activate sklearn-env
```



Les bases de scikit learn



Avec trois méthodes présentes dans toutes les classes de scikit learn



INTERFACE DE SKLEARN

Linear
Regression



Decision
Tree



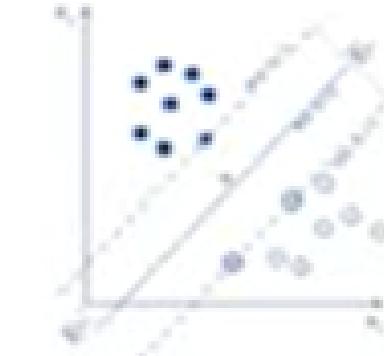
Random
Forest



K-NN



SVM



Neural
Network



*Différents mécanismes
Mais la même interface*



fit

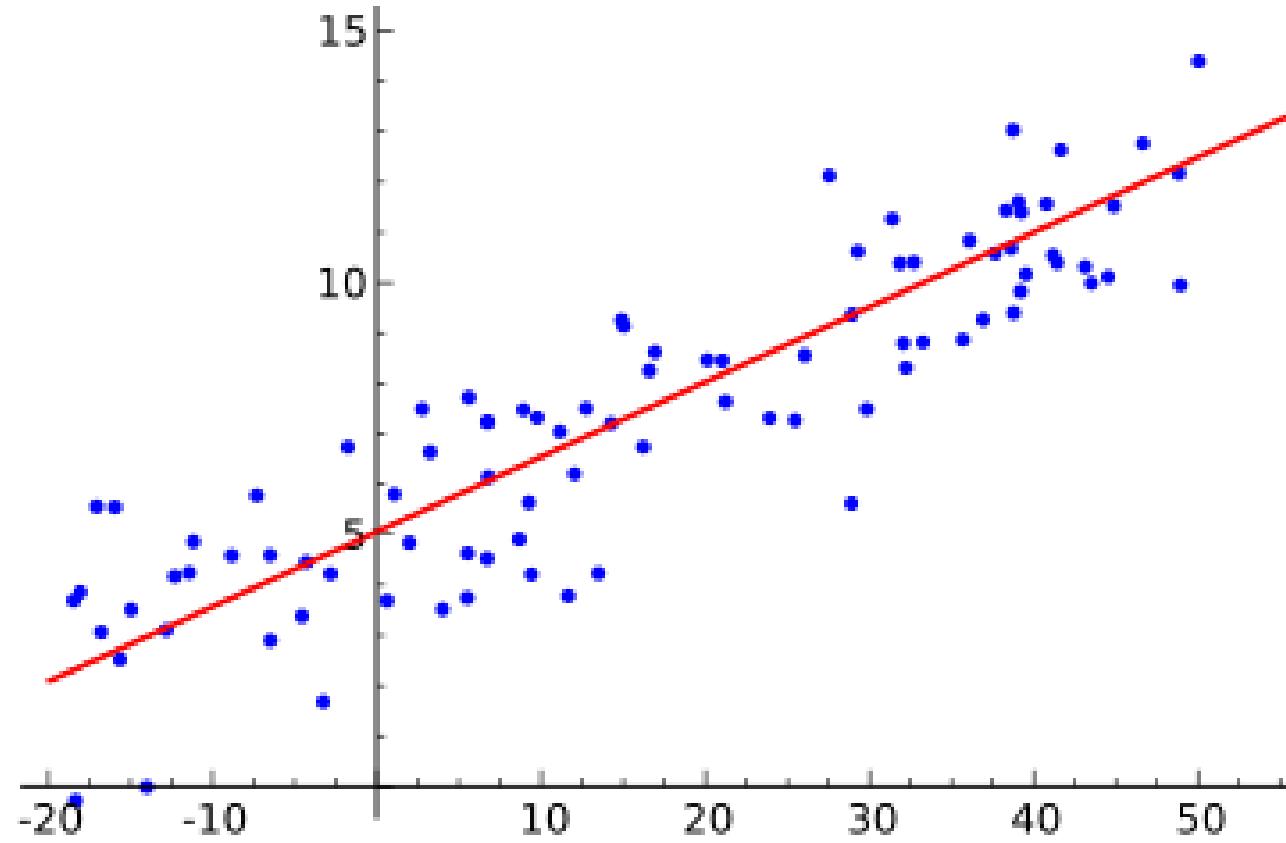


score

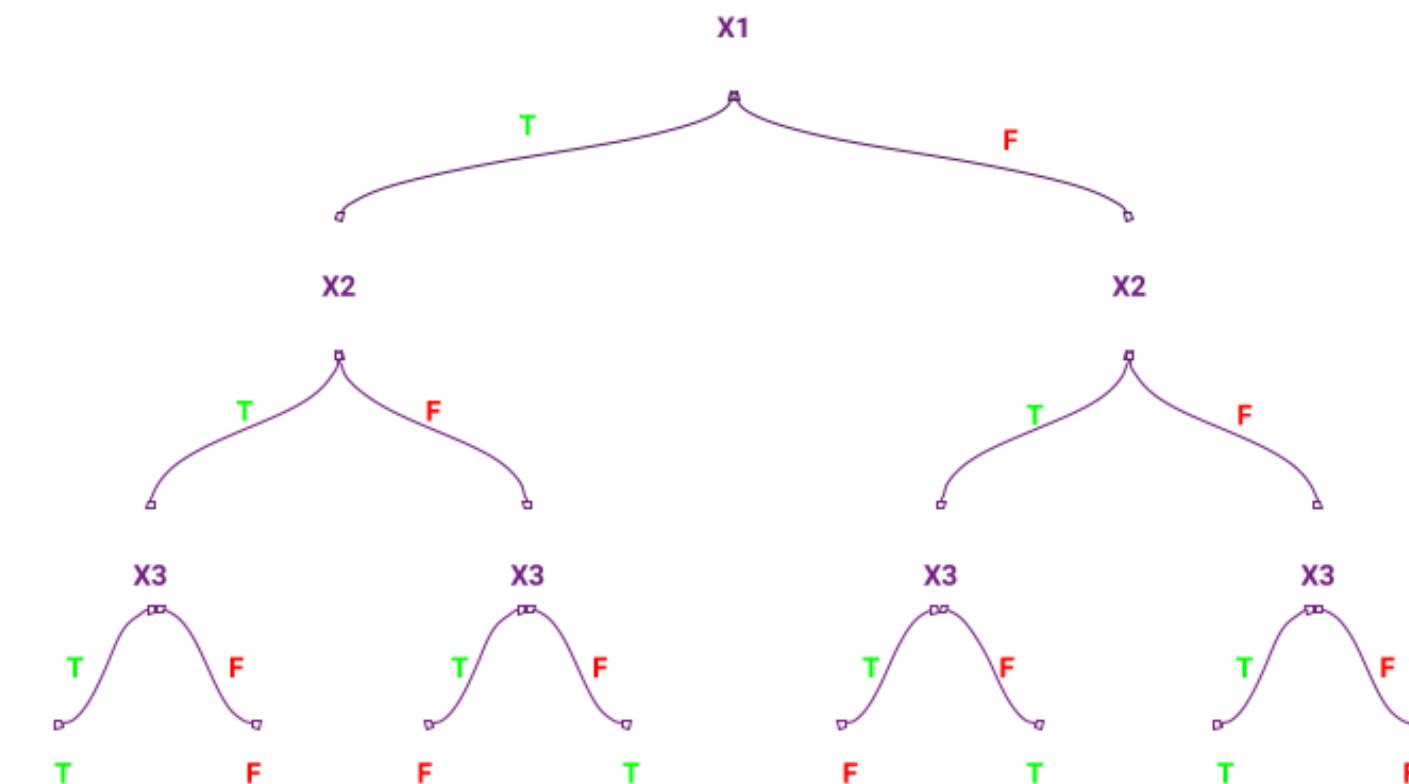


predict

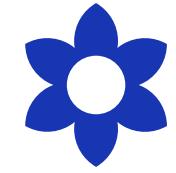




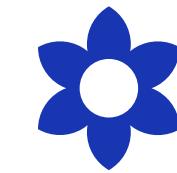
```
model = LinearRegression()  
model.fit(X, y)  
model.score(X, y)  
model.predict(X)
```



```
model = DecisionTreeClassifier()  
model.fit(X, y)  
model.score(X, y)  
model.predict(X)
```



Classification



**Dimensionality
Reduction**



Regression



Model selection

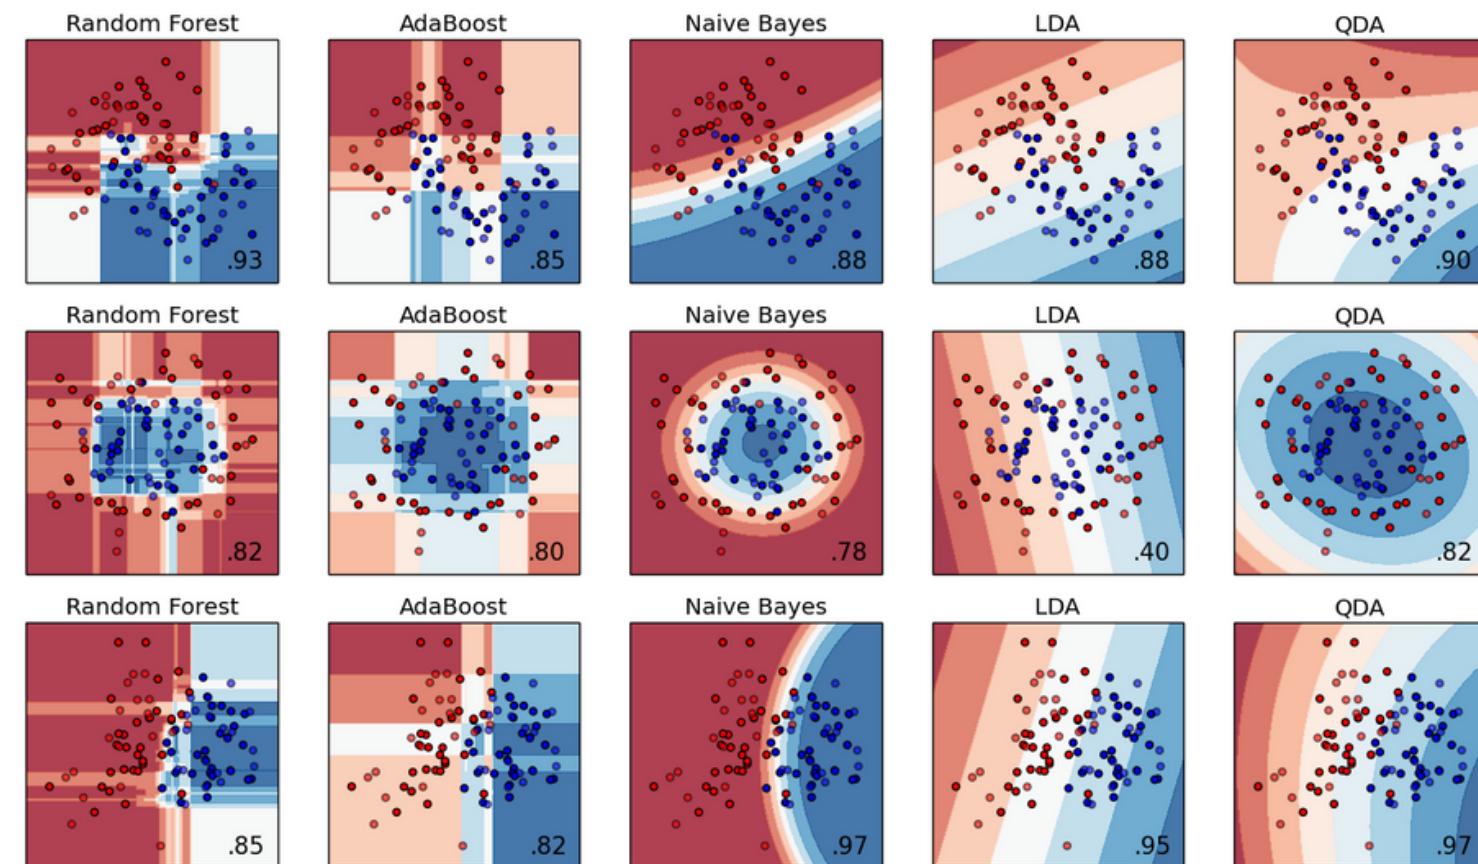


Clustering



Pre-Processing

Classification



Identifier à quelle catégorie appartient un objet.

Applications :
Spam detection
face detection



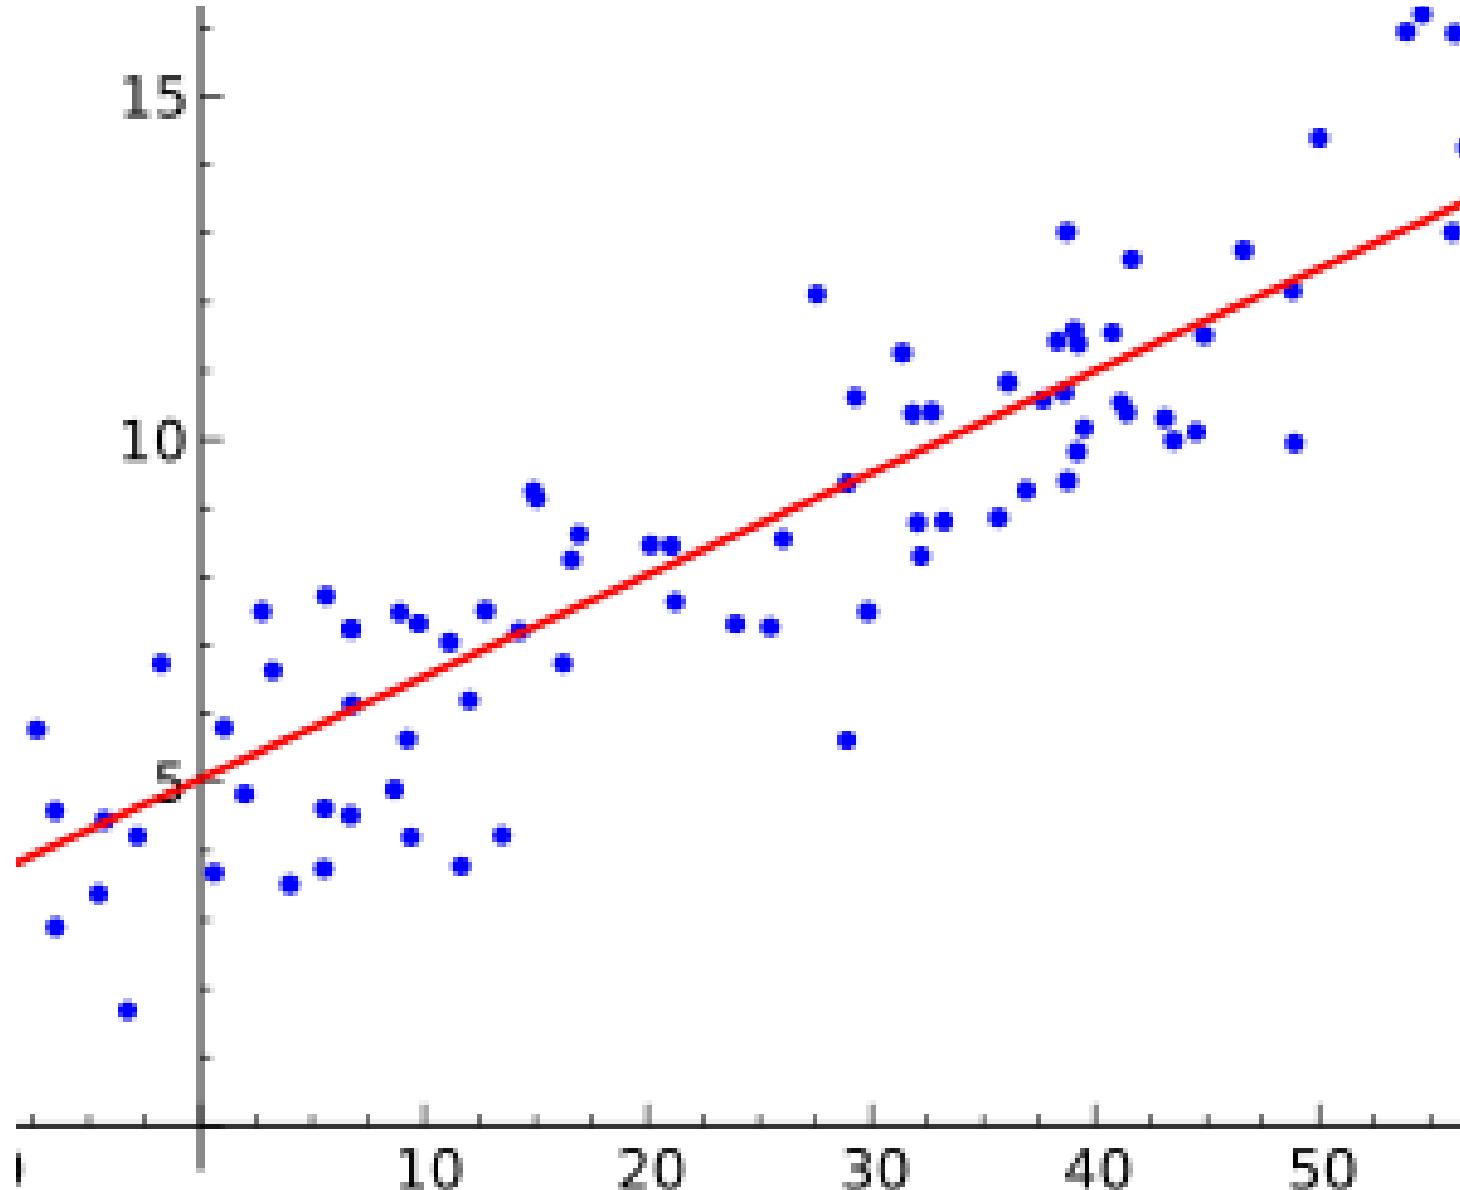
Algorithmes :

SVM, random forest, Linear Models, Nearest
Neighbors, Decision Trees...

Example

```
>>> from sklearn import svm  
>>> X = [[0, 0], [1, 1]]  
>>> y = [0, 1]  
>>> clf = svm.SVC()  
>>> clf.fit(X, y)  
SVC()
```

Regression



Prédire un attribut à valeur continue associé à un objet.

Applications :

Stock prices

Drug response



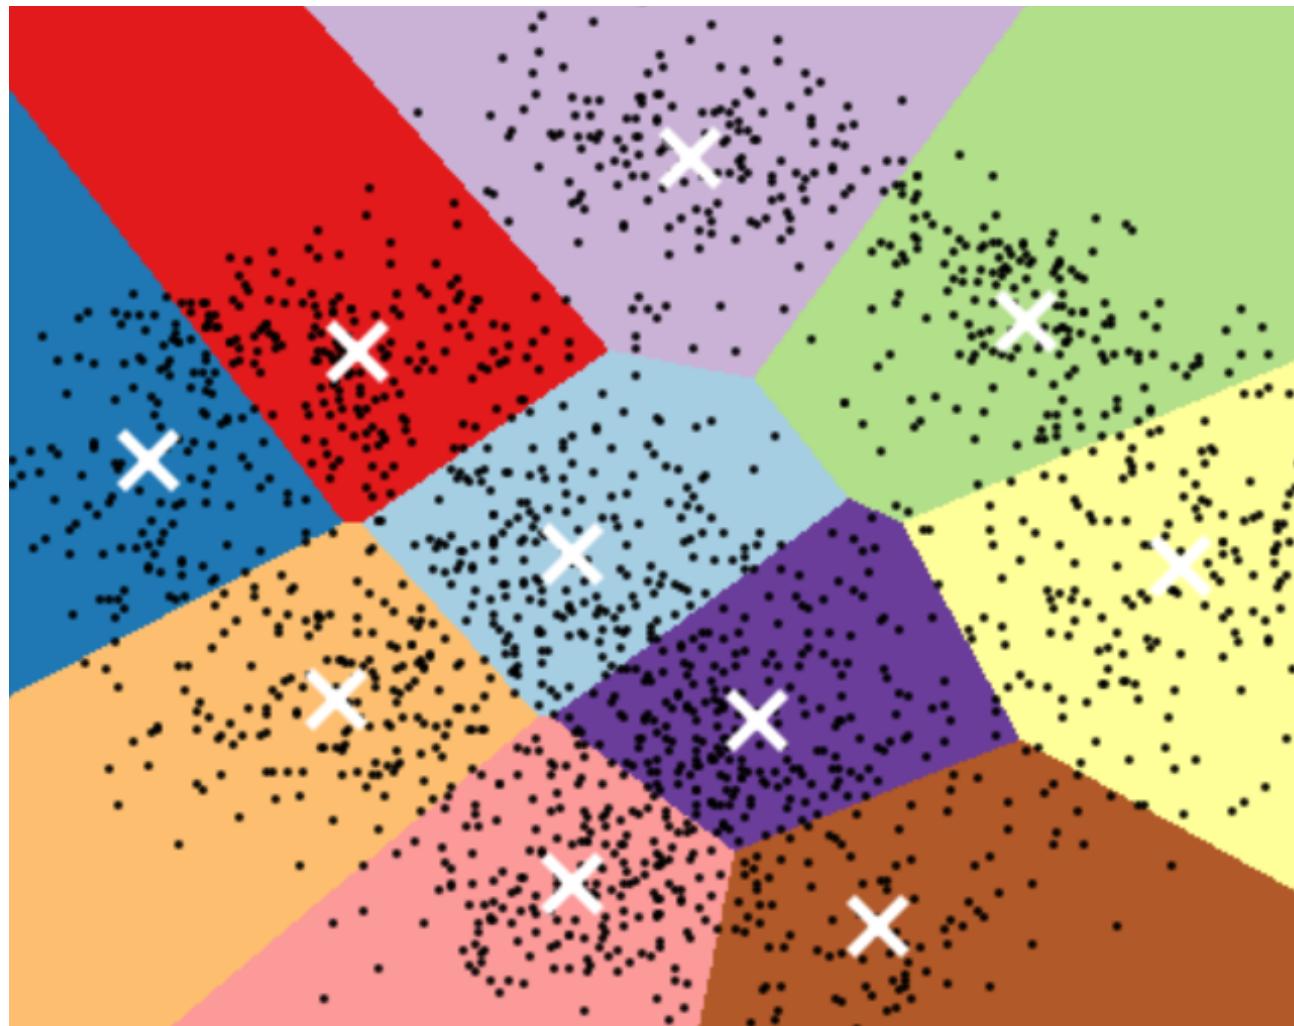
Algorithmes :

SVR, nearest neighbors, random forest, Linear Models

Example

```
>>> from sklearn import linear_model  
>>> reg = linear_model.LinearRegression()  
>>> reg.fit([[0, 0], [1, 1], [2, 2]], [0, 1, 2])  
LinearRegression()  
>>> reg.coef_  
array([0.5, 0.5])
```

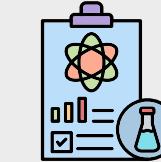
Clustering



Regroupement automatique d'objets similaires en ensembles.

Applications :

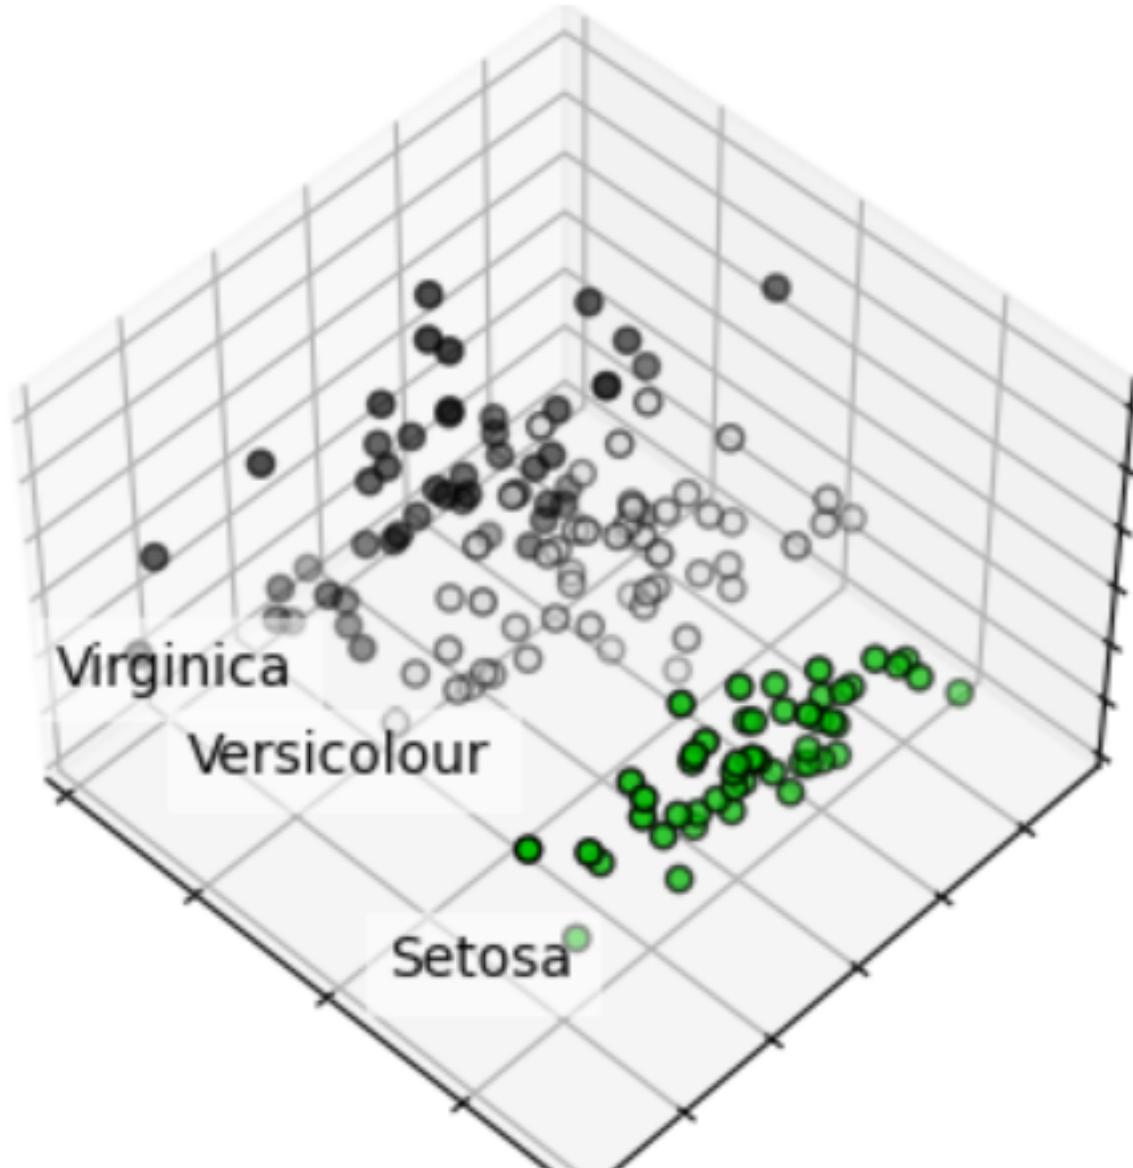
Customer segmentation
Grouping experiment outcomes



Algorithmes :

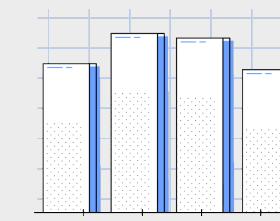
k-Means, spectral clustering, mean-shift...

Dimensionality reduction



Réduire le nombre de variables aléatoires à considérer

Applications :
Visualization
Increased efficiency



Algorithmes :

PCA, feature selection...

Example

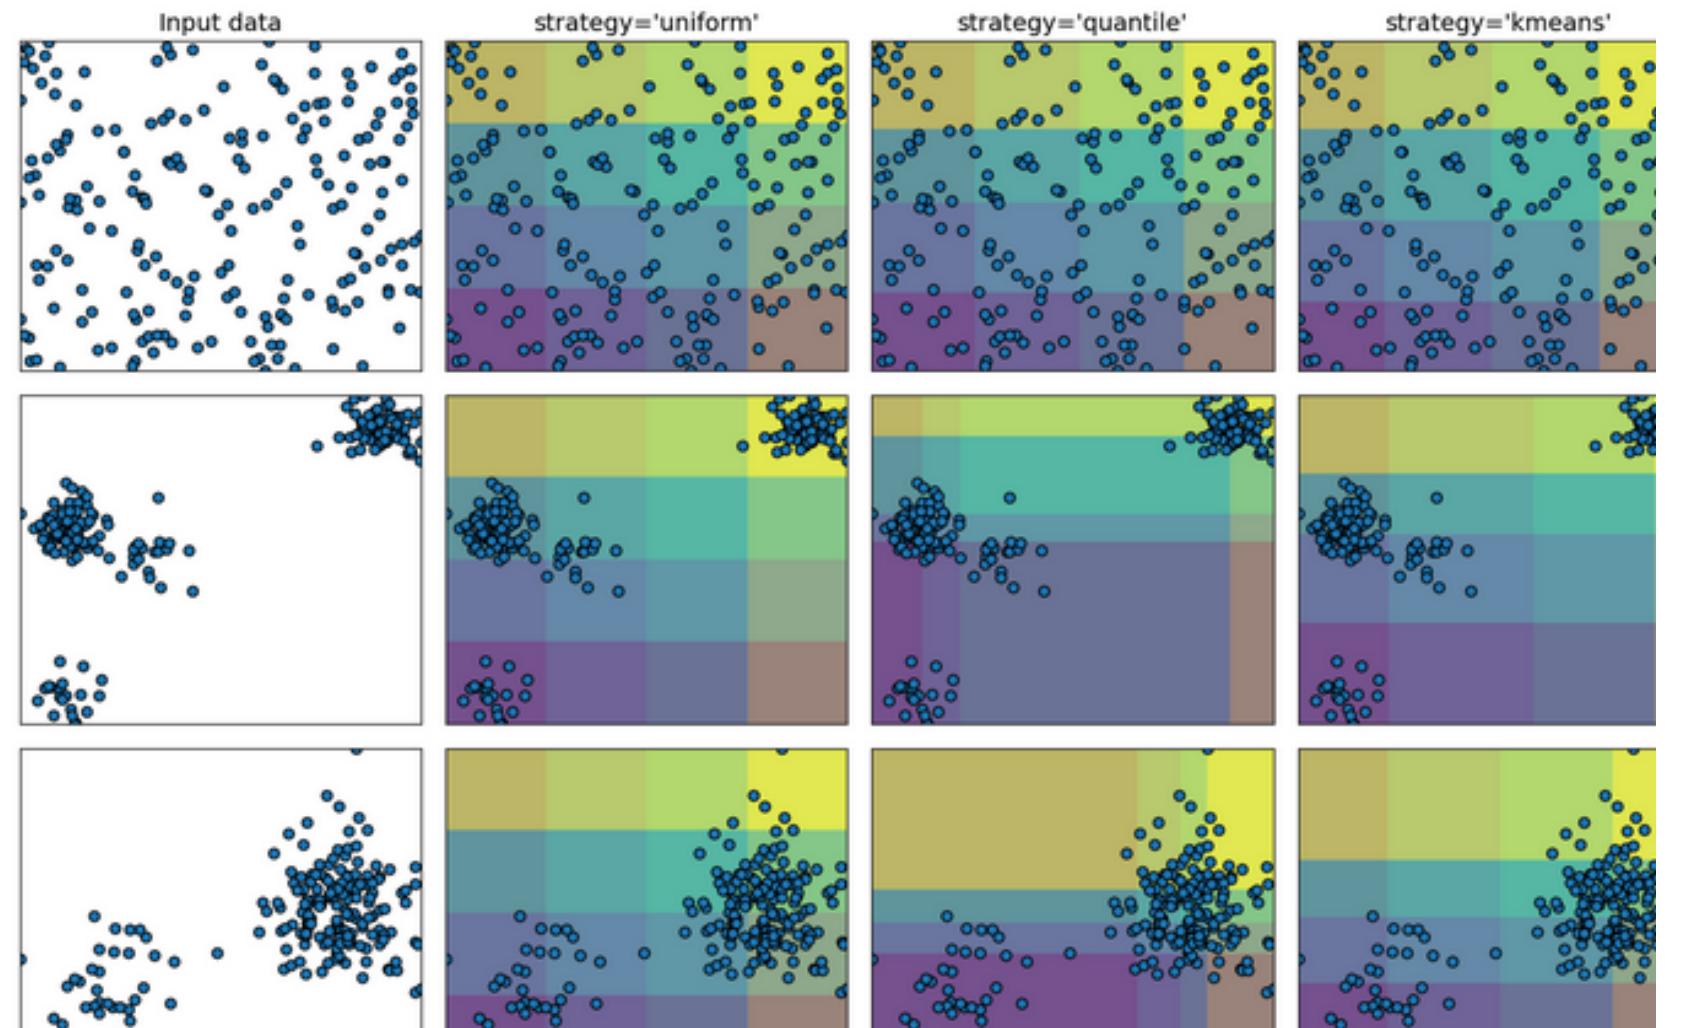
```
✓ 0 s [1] import numpy as np  
      from sklearn.decomposition import PCA  
  
      X = np.array([[-1, -1], [-2, -1], [-3, -2], [1, 1], [2, 1], [3, 2]])  
      X.shape
```

(6, 2)

```
✓ 0 s [2] pca = PCA(n_components=1)  
      pca.fit(X)  
      X = pca.transform(X)  
      X.shape
```

(6, 1)

Pre-Processing



Extraction et normalisation de caractéristiques

Applications :

Transformer les données d'entrée telles que le texte pour les utiliser avec des algorithmes d'apprentissage automatique

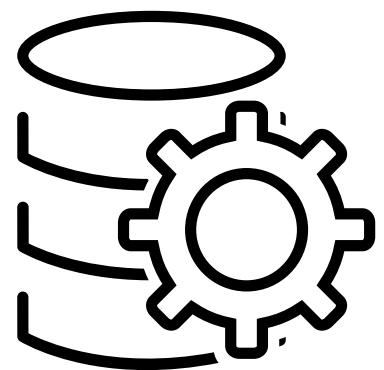


Algorithmes :

preprocessing, feature extraction,

EXAMPLE

```
>>> measurements = [  
...     {'city': 'Dubai', 'temperature': 33.},  
...     {'city': 'London', 'temperature': 12.},  
...     {'city': 'San Francisco', 'temperature': 18.},  
... ]  
  
>>> from sklearn.feature_extraction import DictVectorizer  
>>> vec = DictVectorizer()  
  
>>> vec.fit_transform(measurements).toarray()  
array([[ 1.,  0.,  0., 33.],  
       [ 0.,  1.,  0., 12.],  
       [ 0.,  0.,  1., 18.]])
```



Datasets

scikit-learn est livré avec quelques petits ensembles de données standard qui ne nécessitent pas de télécharger de fichier à partir d'un site Web externe.

Ils peuvent être chargés à l'aide des fonctions suivantes :

`load_boston(*[, return_X_y])`

DÉCONSEILLÉ : `load_boston` est déprécié dans la version 1.0 et sera supprimé dans la version 1.2.

`load_iris(*[, return_X_y, as_frame])`

Chargez et renvoyez l'ensemble de données d'`iris` (classification).

`load_diabetes(*[, return_X_y, as_frame, mis à
l'échelle])`

Chargez et renvoyez l'ensemble de données sur le diabète (régression).

`load_digits(*[, n_class, return_X_y, as_frame])`

Charger et renvoyer le jeu de données `digits` (classification).

`load_linnerud(*[, return_X_y, as_frame])`

Chargez et renvoyez l'ensemble de données d'exercice physique `Linnerud`.

`load_wine(*[, return_X_y, as_frame])`

Chargez et renvoyez le jeu de données de vin (classification).

`load_breast_cancer(*[, return_X_y, as_frame])`

Chargez et renvoyez l'ensemble de données du Wisconsin sur le cancer du sein (classification).

EXAMPLE

```
✓ [3] # Import Libraries  
0 s   from sklearn.datasets import load_iris  
  
      #load iris data  
      IrisData = load_iris()
```

```
[10] #X Data  
      X = IrisData.data  
      print('X shape is ' , X.shape)  
      print('X Features are \n' , IrisData.feature_names)  
      print('X Data is \n' , X[:3])  
  
X shape is (150, 4)  
X Features are  
  ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']  
X Data is  
[[5.1 3.5 1.4 0.2]  
 [4.9 3. 1.4 0.2]  
 [4.7 3.2 1.3 0.2]  
 [4.6 3.1 1.5 0.2]  
 [5.  3.6 1.4 0.2]]
```

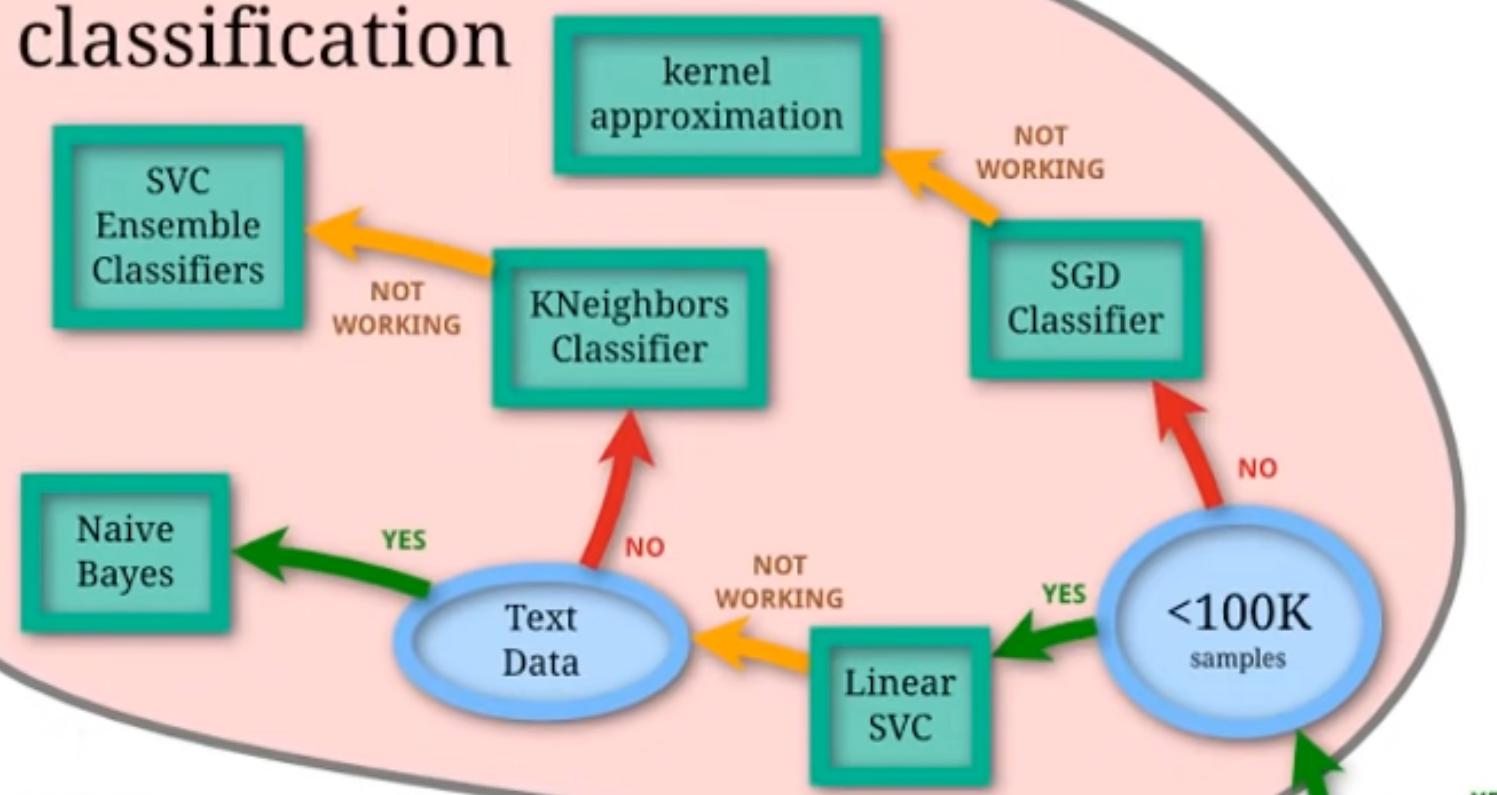
Ces ensembles de données sont utiles pour illustrer rapidement le comportement des différents algorithmes implémentés dans scikit-learn. Ils sont cependant souvent trop petits pour être représentatifs des tâches d'apprentissage automatique du monde réel.

Comment choisir le meilleur algorithme ?

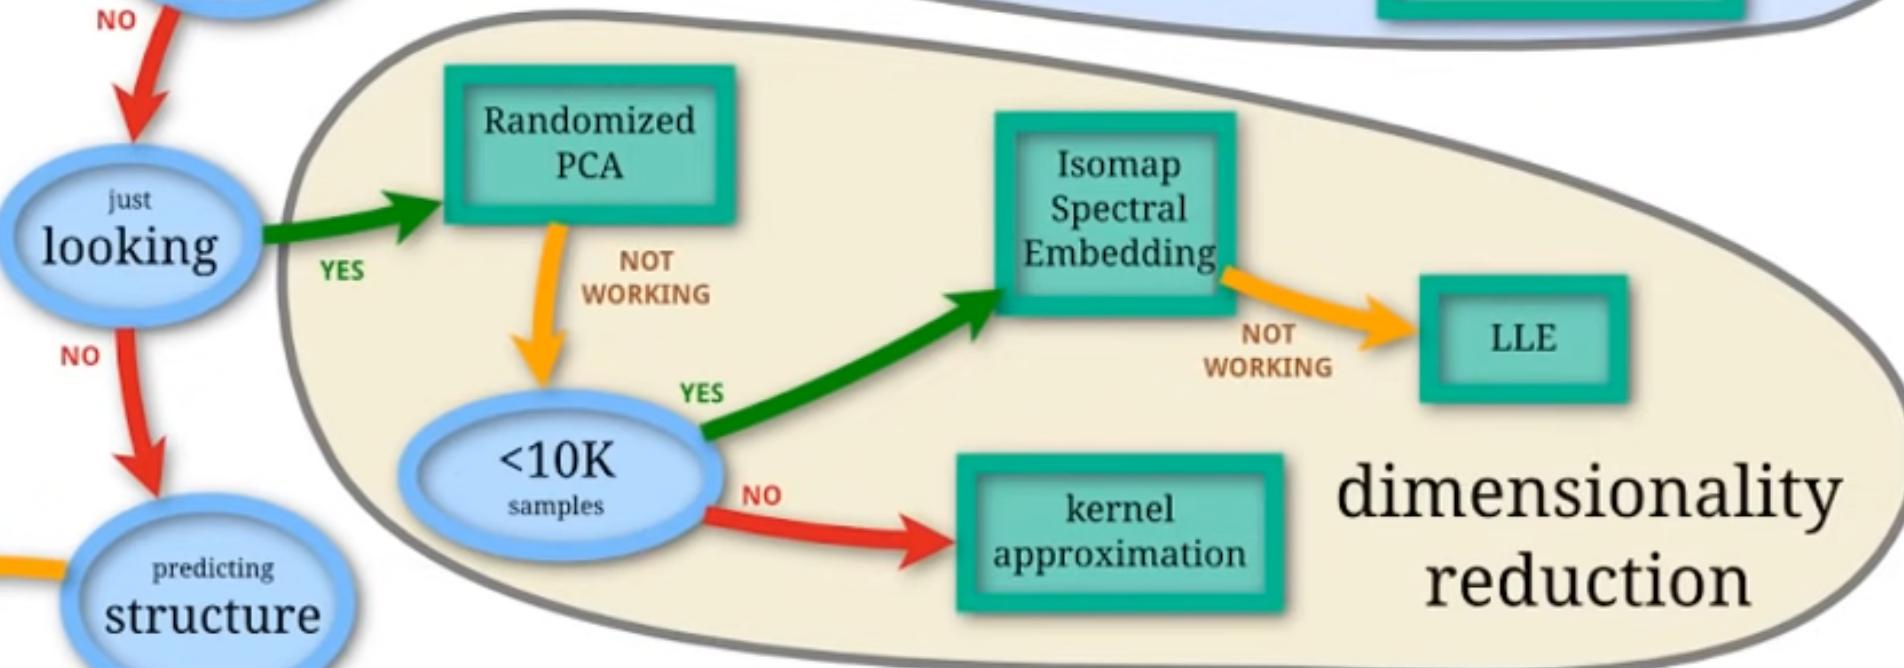
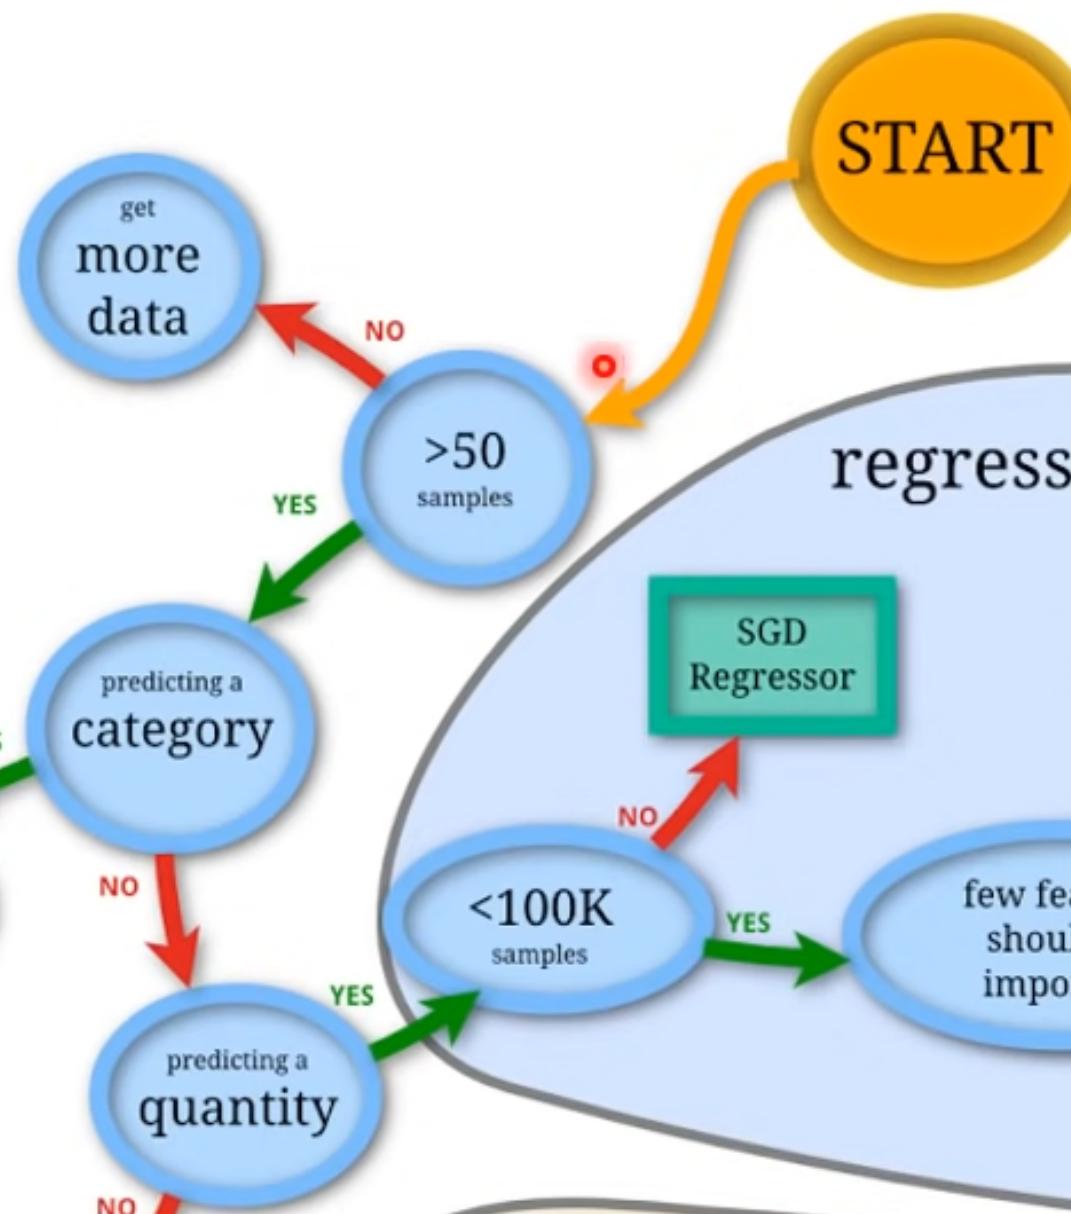
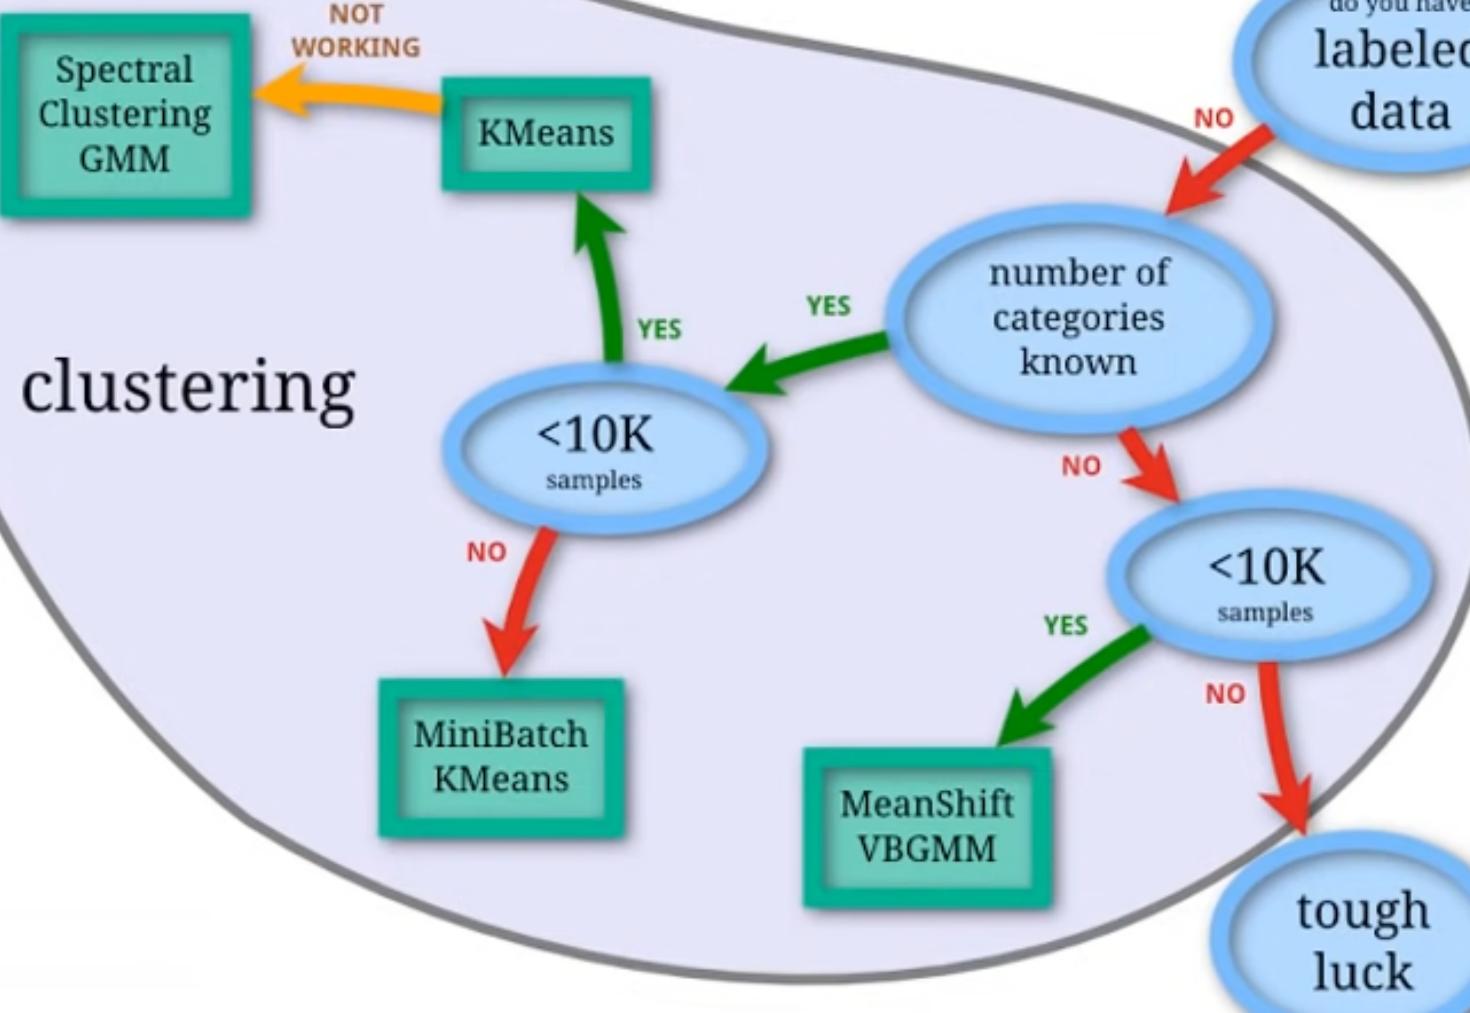


scikit-learn algorithm cheat-sheet

classification



clustering





Démonstration





*Merci pour votre
attention*

The
End